

RetroAir 项目计划书

基于卫星 AOD 与气象数据的历史 PM2.5 回顾性推断系统

选题类别：选项 C——端到端应用系统开发

团队成员：黄一和、夏浩博、黄迪、许君达

2026 年 5 月

1 项目目标

本项目旨在构建一个完整的端到端 $\text{PM}_{2.5}$ 回顾性推断系统。核心思路是利用地面监测站已有的历史 $\text{PM}_{2.5}$ 观测数据作为监督标签，结合该位置的卫星气溶胶光学厚度数据和气象再分析数据，训练回归模型，从而推断无监测站覆盖地区的历史 $\text{PM}_{2.5}$ 浓度。

项目的最终交付物包括：

1. 一套可自动化运行的多源数据获取与融合流水线；
2. 一个经过多算法对比和特征消融验证的最优预测模型；
3. 一个基于 Web 的交互式推理应用，用户可通过地图选点和日期选择获取任意位置的 $\text{PM}_{2.5}$ 估计值。

2 项目背景与动机

2.1 为什么需要这个系统？

$\text{PM}_{2.5}$ 是最主要的空气污染物之一，对呼吸系统和心血管健康有显著危害^[1]。然而，地面空气质量监测站的建设与维护成本极高——我国国控空气站点在“十三五”期间为 1,436 个，“十四五”优化为 1,734 个，主要覆盖地级及以上城市区域^[2]，广大农村和中小城市几乎无覆盖。对于流行病学研究和环境健康评估而言，历史 $\text{PM}_{2.5}$ 的空间缺失是一个长期未解决的问题^[3]。

2.2 技术可行性

近年来，卫星遥感技术提供了全球覆盖的气溶胶数据。欧洲中期天气预报中心旗下的 CAMS EAC4 再分析数据集提供了 2003 年至今的全球气溶胶光学厚度，包含总 AOD 及各组分的浓度估计^[4]。同时，NASA POWER 提供了免费的全球历史气象数据接口^[5]。

已有研究表明，AOD 与地面 $\text{PM}_{2.5}$ 之间存在统计相关性^[6]，且气象条件（温度、湿度、风速等）显著影响气溶胶的扩散与转化^[7]。利用机器学习模型融合卫星遥感与气象数据进行 $\text{PM}_{2.5}$ 估计的方法已被验证可行^[8]。因此，利用 AOD 加气象作为特征、监测站 $\text{PM}_{2.5}$ 作为标签来训练回归模型，在技术上是可行且有文献支持的。

3 数据来源与特征设计

3.1 数据来源

计划使用以下三类公开数据源：

表 1: 计划使用的数据来源

数据	来源	分辨率	覆盖
PM _{2.5} 标签	AKShare 真气网 API	站点级	中国主要城市 2018–2025
气象数据	NASA POWER API	0.5° 日均	全球
气溶胶 AOD	CAMS EAC4 (Copernicus ADS)	0.75° 日均	全球, 2003 年至今

3.2 特征设计

初步计划使用以下特征组进行模型训练:

表 2: 计划使用的特征组

特征组	数量	变量说明
AOD	9	总气溶胶光学厚度、各组分 AOD (沙尘、硫酸盐、黑碳、有机物、海盐) 及波长指数
气象	7	温度、相对湿度、风速、风向、气压、降水、云量
时间	1	年内第几天, 用于捕捉季节性周期

同时, 我们计划探索 OSM 空间特征和 MODIS RGB 地表反射率特征作为潜在补充维度^[9]。若后续消融实验证明其有效, 则加入最终模型; 否则将放弃。

3.3 数据管道设计

计划按以下流程构建自动化数据管道:

1. 调用 AKShare API 逐城市逐日抓取监测站数据, 关联公开站点坐标清单;
2. 根据站点经纬度批量调用 NASA POWER API 获取逐日气象数据;
3. 从 CAMS EAC4 NetCDF 文件中按经纬度和日期提取 AOD 特征值;
4. 以 (城市, 站点名称, 日期) 为键执行 inner join, 补充时间编码;
5. 合并各城市独立数据集为全国多城训练集。

4 模型方案与评估策略

4.1 模型选择

计划实现并对比 5 至 6 种回归算法, 覆盖树模型与深度学习两大类:

- 树模型: LightGBM、XGBoost、CatBoost;
- 深度学习: ResMLP、DCN-V2、FT-Transformer。

4.2 评估策略

- **数据切分**：由于本任务是空间插值而非时间预测，采用随机切分策略评估模型在整体历史分布上的拟合和泛化能力；
- **评估指标**： R^2 、RMSE、MAE、SMAPE、MAPE、Pearson 相关系数、Explained Variance；
- **消融实验**：对气象、AOD、OSM、RGB 四个特征维度做排列组合实验（共 15 组），确定最优特征组合。

4.3 模型部署

训练完成后，将最优模型的权重与特征定标器保存为文件，供 Web 应用加载推理使用。

5 Web 应用设计

计划使用 Streamlit 框架构建轻量级交互式 Web 界面，提供以下功能：

- 地图交互选点，用户可通过点击地图或拖动方式选择目标位置；
- 城市快捷选择，预设国内外主要城市坐标便于快速测试；
- 日期选择，覆盖 2018 年至 CAMS 最新可用年份；
- 一键预测，系统自动完成气象获取、AOD 提取、特征标准化和模型推理；
- 特征详情，用户可展开查看具体的气象与 AOD 数值，增强结果透明度。

6 团队分工

团队四人按模块解耦分工，各自负责独立的子系统，通过明确的接口（数据格式、函数签名、文件路径）进行协作。各成员分工如下：

表 3: 团队分工方案

成员	角色	职责说明
黄一和	算法核心	负责 AOD 特征提取模块；设计并实现所有神经网络模型；搭建 PyTorch 训练框架；对深度学习模型进行训练与调优，并向夏浩博提供模型训练所需的特征数据格式规范
夏浩博	数据工程	负责地面监测站 PM _{2.5} 数据获取与清洗；气象数据批量下载与校验；多源数据合并与去重；构建整体数据管道编排脚本，向算法和评估模块输出统一格式的训练数据集
黄迪	实验评估	负责树模型的实现与超参调优；设计并执行特征维度消融实验；搭建多算法统一对比框架；生成模型性能可视化图表；基于实验结果向全组推荐最优特征组合与部署模型
许君达	工程部署	负责数据加载工具与评估指标模块；模型 I/O 与推理管线封装；开发基于 Streamlit 的交互式 Web 应用；项目文档撰写与演示材料准备

上述分工中，各成员的输出产品（数据集、模型文件、评估报告、Web 应用）具有明确的交付边界：数据工程输出训练集，算法核心输出训练好的模型权重，实验评估输出对比结果和特征选择建议，工程部署将这些组件集成为可运行的用户界面。成员之间的协作接口在项目启动阶段即约定好数据格式和文件路径，后续各模块可独立开发与调试。

7 时间规划

表 4: 项目时间规划

阶段	里程碑与产出
第 13 周	确定选题 C；评估各数据源的可行性与覆盖范围；搭建项目骨架与 Git 仓库；约定模块间接口规范
第 14 周	完成 AQI、气象、AOD 三源数据获取脚本；实现数据合并与清洗流程；构建单城市训练数据集
第 15–16 周	实现全部计划模型；执行特征维度消融实验，确定最优特征组合；完成多算法对比实验
第 16–17 周	构建 Streamlit 交互界面；集成推理管线；前后端联调测试；保存部署模型与定标器
第 17–18 周	撰写项目报告（学术论文格式）；制作演示 PPT；录制系统演示视频；整理代码仓库

8 预期成果

- 一套可自动化运行的数据管道，支持按城市和年份构建训练数据集；
- 一个经过严格消融实验验证的最优模型，预期在测试集上 $R^2 > 0.85$ ；
- 一个可交互的 Web 推理应用，支持任意位置的历史 $\text{PM}_{2.5}$ 推断；
- 一份完整的技术报告，包含方法、实验、分析与结论。

9 风险与应对

表 5: 风险分析与应对措施

风险	应对措施
CAMS AOD 数据更新滞后（通常 3 个月）	对近期日期采用最近可用年份回退
NASA POWER API 请求限流	使用多线程搭配本地缓存，减少重复请求
部分特征维度无显著贡献	通过消融实验提前排除（如确有必要，放弃 OSM、RGB 等辅助维度）
团队模块集成困难	项目启动阶段约定统一的数据格式与接口规范，各模块独立测试后再集成

参考文献

- [1] World Health Organization. *WHO global air quality guidelines: particulate matter (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*. 2021.
- [2] 中华人民共和国生态环境部. 《对十三届全国人大三次会议第 6307 号建议的答复》. 2020.
- [3] Holloway, T., Miller, D., Anenberg, S., et al. *Satellite Monitoring for Air Quality and Health*. Annual Review of Biomedical Data Science, Vol. 4, pp. 417–447, 2021. <https://doi.org/10.1146/annurev-biodatasci-110920-093120>
- [4] Copernicus Atmosphere Monitoring Service / ECMWF. *CAMS global re-analysis (EAC4)*. <https://ads.atmosphere.copernicus.eu/datasets/cams-global-reanalysis-eac4>
- [5] NASA POWER Project. *Daily API Documentation*. <https://power.larc.nasa.gov/docs/services/api/temporal/daily/>
- [6] Xin, J., et al. *The observation-based relationships between PM_{2.5} and AOD over China*. Journal of Geophysical Research: Atmospheres, 2016.
- [7] Zheng, Y., et al. *Analysis of influential factors for the relationship between PM_{2.5} and AOD in Beijing*. Atmospheric Chemistry and Physics, 2017.
- [8] Wei, J., Huang, W., Li, Z., Xue, W., Peng, Y., Sun, L., & Cribb, M. *Estimating 1-km-resolution PM_{2.5} concentrations across China using the space-time random forest approach*. Remote Sensing of Environment, 2019.
- [9] Li, L., et al. *Mining Public Datasets for Modeling Intra-City PM_{2.5} Concentrations at a Fine Spatial Resolution*. Proceedings of the ACM SIGKDD International Workshop on Urban Computing, 2017.